

























- Eliminação de *stopwords*
- *document frequency thresholding*
  - Conjuntura de Apté e Damerau

- Ganho de informação:

$$\sum_{y \in \{-1, +1\}} \sum_{w \in \{0, 1\}} Pr(y, w) \frac{Pr(y, w)}{Pr(y)Pr(w)}$$

- Razão de Chances
- Testes  $\chi^2$































## Limite Superior

- Quanto menor a dimensão VC de uma função, maior sua capacidade de generalização
- Minimização do Risco Estrutural

## Conceito de Margem

## Definição (Margem)

*A margem de um classificador é definida como a menor distância entre os exemplos do conjunto de treinamento e o hiperplano utilizado na separação desses dados em classes.*



## Conceito de Margem

- Quanto maior a margem de um classificador, menor sua dimensão VC.



## Conceito de Margem

### Teorema (Continuação)

*Seja  $G$  o conjunto de funções  $g(x) = \text{sgn}(f(\vec{x})) = \text{sgn}(\vec{w} \cdot \vec{x})$  com  $\|\vec{w}\| \leq \Lambda$  e  $\|\vec{x}\| \leq R$ , para algum  $R, \Lambda > 0$ . Seja  $\rho > 0$ . Para todas distribuições  $P$  gerando os dados, com probabilidade de ao menos  $1 - \delta$  sobre  $n$  exemplos, e para qualquer  $\rho > 0$  e  $\delta \in (0, 1)$ , a probabilidade de um ponto de teste amostrado independentemente segundo  $P$  ser classificado incorretamente é limitado superiormente por*

$$R_\rho(g) + \sqrt{\frac{c}{n} \left( \frac{R^2 \Lambda^2}{\rho^2} \ln^2 n + \ln \left( \frac{1}{\rho} \right) \right)}$$

*em que  $c$  é uma constante universal.*

## Conceito de Margem

- Minimização do erro
  - sobre os dados de teste: margem  $\rho$  alta
  - sobre os dados de treinamento: poucos erros marginais
- Propriedades do hiperplano ótimo:
  - robustez em relação aos padrões
  - robustez em relação aos parâmetros



# SVMs Lineares com Margens Rígidas

- Conjunto de treinamento linearmente separável
- Classificador linear:  $\vec{w} \cdot \vec{x} + b = 0$

$$\begin{cases} y_i = +1 & \text{se } \vec{w} \cdot \vec{x}_i + b > 0 \\ y_i = -1 & \text{se } \vec{w} \cdot \vec{x}_i + b < 0 \end{cases}$$



# Obtenção do Hiperplano Ótimo

- Pela ortogonalidade entre o hiperplano separador e  $\vec{w}$  e  $\vec{x}_2 - \vec{x}_1$

$$|\vec{w} \cdot (\vec{x}_2 - \vec{x}_1)| = \|\vec{w}\| \times \|\vec{x}_2 - \vec{x}_1\|$$

- Substituindo

$$\|\vec{x}_2 - \vec{x}_1\| = \frac{2}{\|\vec{w}\|}$$

- Logo,
  - distância entre os hiperplanos  $\vec{w} \cdot \vec{x} + b = 0$  e  $\vec{w} \cdot \vec{x} + b = 1$  ou  $\vec{w} \cdot \vec{x} + b = -1$  é dada por  $\frac{1}{\|\vec{w}\|}$ .

# Problema de Otimização Quadrática

$$\begin{aligned} \text{minimizar : } & \|\vec{w}\|^2 \\ \text{sujeito a : } & y_i(\vec{w} \cdot \vec{x}_i + b) \geq 1 \quad \text{para } i = 1, \dots, n \end{aligned}$$

# Função Lagrangiana

$$L(\vec{w}, b, \alpha) = \frac{1}{2} \|\vec{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i(\vec{w} \cdot \vec{x}_i + b) - 1)$$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

$$\vec{w} = \sum_{i=1}^n \alpha_i y_i \vec{x}_i$$

## Problema Dual de Otimização

$$\begin{aligned}
 \text{maximizar : } & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \vec{x}_i \cdot \vec{x}_j \\
 \text{sujeito a : } & \begin{cases} \alpha_i \geq 0, \quad i = 1, \dots, n \\ \sum_{i=1}^n \alpha_i y_i = 0 \end{cases}
 \end{aligned}$$

# Solução

- $\alpha_i^*$  assume valores positivos para exemplos de treinamento que estão a uma distância do hiperplano ótimo exatamente igual à margem (chamados vetores de suporte) e zero para todos os outros

- $$\vec{w}^* = \sum_{i=1}^n \alpha_i^* y_i \vec{x}_i$$

- $$b^* = -\frac{1}{2} \left[ \max_{i|y_i=-1} (\vec{w}^* \cdot \vec{x}_i) + \min_{i|y_i=+1} (\vec{w}^* \cdot \vec{x}_i) \right]$$

- Classificação:

$$\text{sgn} \left( \sum_{x_i \in SV} \alpha_i^* y_i \vec{x}_i \cdot \vec{x} + b^* \right)$$

# SVMs Lineares com Margens Suaves

- Problema não linear ou muito ruído nos dados
- Variáveis de relaxamento  $\xi$ 
  - Medem onde se encontram os exemplos  $(\vec{x}_i, y_i)$  em relação aos hiperplanos  $\vec{w} \cdot \vec{x} + b = \pm 1$  nos casos em que a classificação está incorreta

$$\text{Para } y_i = +1 \quad \xi_i(\vec{w}, b) = \begin{cases} 0 & \text{se } \vec{w} \cdot \vec{x}_i + b \geq 1 \\ 1 - \vec{w} \cdot \vec{x}_i + b & \text{se } \vec{w} \cdot \vec{x}_i + b < 1 \end{cases}$$

$$\text{Para } y_i = -1 \quad \xi_i(\vec{w}, b) = \begin{cases} 0 & \text{se } \vec{w} \cdot \vec{x}_i + b \leq -1 \\ 1 + \vec{w} \cdot \vec{x}_i + b & \text{se } \vec{w} \cdot \vec{x}_i + b > -1 \end{cases}$$



# Problema de Otimização Quadrática

- Variável auxiliar  $\zeta$  tal que  $\zeta_i \geq \xi_i(\vec{w}, b)$

$$\text{minimizar : } \|\vec{w}\|^2 + C \sum_{i=1}^n \zeta_i$$

$$\text{sujeito a : } \begin{cases} \zeta_i \geq 0 \\ y_i(\vec{w} \cdot \vec{x}_i + b) \geq 1 - \zeta_i \end{cases}$$

# Condições de Karush-Kuhn-Tucker

- $\alpha_i = 0 \Rightarrow y_i f(\vec{x}_i) \geq 1$  e  $\zeta_i = 0$
- $0 < \alpha_i < C \Rightarrow y_i f(\vec{x}_i) = 1$  e  $\zeta_i = 0$
- $\alpha_i = C \Rightarrow y_i f(\vec{x}_i) < 1$  e  $\zeta_i \geq 0$

# SVMs Não-Lineares

- Funções reais  $\phi_1, \dots, \phi_M$  que mapeiam o conjunto de treinamento  $S$  para o *espaço de características* de forma a torná-lo linearmente separável

$$\vec{\Phi}(S) = \{(\vec{\Phi}(\vec{x}_1), y_1), \dots, (\vec{\Phi}(\vec{x}_n), y_n)\}$$

- Basta saber calcular o produto interno  $\vec{\Phi}(\vec{x}_i) \cdot \vec{\Phi}(\vec{x}_j)$

$$K(x, z) = \Phi(x) \cdot \Phi(z)$$

- Teorema de Mercer: os kernels devem ser matrizes positivas semi-definidas para qualquer subconjunto finito de  $S$

# Principais Kerneis

Tipo de Kernel	Função $K(\vec{x}_i, \vec{x}_j)$	Comentários
Polinomial	$(\vec{x}_i \cdot \vec{x}_j + 1)^p$	A potência $p$ deve ser especificada pelo usuário
Gaussiano	$e^{(-\frac{1}{2\sigma^2} \ \vec{x}_i - \vec{x}_j\ ^2)}$	A amplitude $\sigma^2$ é especificada pelo usuário
Sigmoidal	$\tanh(\beta_0(\vec{x}_i \cdot \vec{x}_j) + \beta_1)$	Utilizado somente para alguns valores de $\beta_0$ e $\beta_1$

# SVMs Incrementais

- Vantagens:
  - tornar os aprendizados sucessivos mais rápidos
  - reduzir o custo de armazenamento descartando exemplos

# Algoritmo $\alpha$ -ISVM

- 3 conceitos:
  - conjunto de backup: exemplos que nunca são selecionados como vetores de suporte (*intra-sample*)
  - conjunto de cache: exemplos que freqüentemente aparecem como vetores de suporte (*vice-boundary sample*)
  - conjunto de trabalho: exemplos do último conjunto de vetores de suporte (*boundary sample*)

# Algoritmo $\alpha$ -ISVM

- Método Iterativo:
  1. classificador antigo é utilizado no novo conjunto de exemplos incremental
    - aqueles que forem classificados incorretamente são combinados ao conjunto de vetores de suporte atual para construir um novo conjunto de treinamento,
    - os outros exemplos formam um novo conjunto de testes.
  2. novo classificador é treinado no novo conjunto de treinamento
  3. novo conjunto de testes é utilizado para repetir a operação anterior

# Algoritmo $\alpha$ -ISVM

- Medidas para reduzir o custo de armazenagem e acelerar a convergência:
  - exemplos do conjunto de backup são descartados gradualmente usando o esquema LRU
  - exemplos do conjunto de trabalho são diretamente introduzidos no conjunto de treinamento
  - exemplos do conjunto de cache são introduzidos no conjunto de treinamento de acordo com uma certa prioridade







# Conceitos TCat Homogêneos

## Definição (Conceitos TCat Homogêneos)

*O conceito TCat*

$$TCat([p_1 : n_1 : f_1], \dots, [p_s : n_s : f_s])$$

*descreve uma tarefa de classificação binária com  $s$  conjuntos disjuntos de características. O  $i$ -ésimo conjunto inclui  $f_i$  características. Cada exemplo positivo contém  $p_i$  ocorrências de características do conjunto respectivo, e cada exemplo negativo contém  $n_i$  ocorrências. Uma mesma característica pode ocorrer múltiplas vezes em um documento.*

## Conceitos TCat Homogêneos

- Exemplo:

TCat( [20 : 20 : 100], [4 : 1 : 200], [1 : 4 : 200], [5 : 5 : 600],  
[9 : 1 : 3000], [1 : 9 : 3000], [10 : 10 : 4000] )

- Propriedades

- alta dimensão do espaço de entrada
- vetor de documento esparsos
- alto nível de redundância
- uso heterogêneo de termos
- Lei de Zipf

# Conceitos TCat Homogêneos

$$h(\vec{x}) = \vec{w} \cdot \vec{x} + b = \sum_{i=1}^{11100} w_i x_i + b$$

com  $b = 0$  e

$$w_i = \begin{cases} +0.23 & \text{para as 200 palavras de média frequência indicando POS} \\ -0.23 & \text{para as 200 palavras de média frequência indicando NEG} \\ +0.04 & \text{para as 3000 palavras de baixa frequência indicando POS} \\ -0.04 & \text{para as 3000 palavras de baixa frequência indicando NEG} \\ 0 & \text{para todas as outras palavras} \end{cases}$$

$\Rightarrow$  margem  $\delta: \sqrt{1/30}, 15$











## Capacidade de Aprendizagem de Conceitos TCat

## Teorema (Continuação)

$$\varepsilon(Err^n(h_{SVM})) \leq \rho \frac{R^2}{n+1} \frac{ac - b^2}{a+2b+c} \text{ com}$$

$$a = \sum_{i=1}^s \frac{p_i^2}{f_i}$$

$$b = \sum_{i=1}^s \frac{p_i n_i}{f_i}$$

$$C = \sum_{i=1}^S \frac{n_i^2}{f_i}$$

$$R^2 = \sum_{i=1}^s \left( \frac{c}{(r+k)^\phi} \right)^2$$

a não ser que  $\forall_{i=1}^S : p_i = n_i$ .

$d$  é escolhido tal que  $\sum_{r=1}^d \frac{c}{(r+k)^\phi} = l$ .











# FIM